

Logistic 推导

Sigmoid 的一个重要特性是其求导函数可以用其本身来表达。

$$\text{Sigmoid 函数 } y = \frac{1}{1+e^{-z}}$$
$$y' = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} = y(1-y)$$

线性回归模型的公式为 $z = w^T x + b$

将上式代入 sigmoid 函数: $y = \frac{1}{1+e^{-(w^T x + b)}}$

对上式进行转换并取对数:

$$y = 1 - y \cdot [e^{-(w^T x + b)}]$$
$$\frac{y}{1-y} = e^{-(w^T x + b)}$$
$$\ln \frac{y}{1-y} = w^T x + b \quad \text{式(1)}$$

式(1)即为对数几率回归的模型表达式。如果将 y 看作是样本作为正例的可能性,那么 $1-y$ 即为样本作为反例的概率。 $\frac{y}{1-y}$ 也称“几率”(odds),对几率取对数则得到对数几率。

为了确定模型参数 w 和 b , 我们需要推导对数几率回归的损失函数,然后对损失函数进行最小化,得到 w 和 b 的估计值。将式(1)中的 y 视为类后验

概率估计 $P(y=1|x)$, 则对数几率回归模型表达式可重写为:

$$\ln \frac{P(y=1|x)}{P(y=0|x)} = w^T x + b$$
$$\frac{P(y=1|x)}{P(y=0|x)} = e^{w^T x + b} = \frac{e^{w^T x + b}}{1 + e^{w^T x + b}} \quad P(y=1|x) = \frac{e^{w^T x + b}}{1 + e^{w^T x + b}} = \hat{y} \quad P(y=0|x) = \frac{1}{1 + e^{w^T x + b}} = 1 - \hat{y}$$

综合上述结果综合可得: $P(y|x) = \hat{y}^y (1-\hat{y})^{1-y}$

对上式两边取对数,并取负号:

$$-\ln P(y|x) = -\frac{1}{m} \sum_{i=1}^m y \ln \hat{y} + (1-y) \ln (1-\hat{y}) \quad \text{式(2)}$$

式(2)就是经典的交叉熵损失函数,令 $L = \ln P(y|x)$, 基于 L 分别对 w 和 b 求偏导。

$$\text{化简式(2)为 } L = -\frac{1}{m} \sum_{i=1}^m \left[y \cdot \ln \frac{1}{1+e^{-(w^T x + b)}} + (1-y) \ln \frac{e^{-(w^T x + b)}}{1+e^{-(w^T x + b)}} \right]$$
$$= \frac{1}{m} \sum_{i=1}^m \left[y(w^T x + b) - \ln \frac{e^{-(w^T x + b)}}{1+e^{-(w^T x + b)}} \right] = \frac{1}{m} \sum_{i=1}^m \left[y(w^T x + b) - \ln \left(1 - \frac{1}{1+e^{-(w^T x + b)}} \right) \right]$$

$$\frac{\partial L}{\partial w} = \frac{1}{n} \sum_{i=1}^m \left[y \cdot x - \frac{1 + e^{-(w^T x + b)}}{e^{-(w^T x + b)}} \cdot \frac{e^{-(w^T x + b)} \cdot x}{(1 + e^{-(w^T x + b)})^2} \right] = \frac{1}{n} \sum_{i=1}^m \left[yx - \frac{1}{1 + e^{-(w^T x + b)}} \cdot x \right]$$

$$= \frac{1}{n} \sum_{i=1}^m (y - \hat{y})x = -\frac{1}{n} \sum_{i=1}^m (\hat{y} - y)x$$

$$\frac{\partial L}{\partial b} = \frac{1}{n} \sum_{i=1}^m \left[y - \frac{1 + e^{-(w^T x + b)}}{e^{-(w^T x + b)}} \cdot \frac{e^{-(w^T x + b)}}{(1 + e^{-(w^T x + b)})^2} \right] = \frac{1}{n} \sum_{i=1}^m (y - \hat{y}) = -\frac{1}{n} \sum_{i=1}^m (\hat{y} - y)$$

基于 w 和 b 的梯度下降对交叉熵损失最小化,相应的参数即为模型最优参数。