

PCA 原理推导

PCA使用方差来衡量新变量的信息量大小,按照方差大小排序依次为第一主成分、第二主成分等。下面对PCA原理进行简单推导。

假设原始数据为 m 维随机变量 $x = (x_1, x_2, \dots, x_m)^T$, 其均值向量 $\mu = E(x) = (\mu_1, \mu_2, \dots, \mu_m)^T$, 协方差矩阵为:

$$\Sigma = \text{cov}(x, x) = E[(x - \mu)(x - \mu)^T]$$

由 m 维随机变量 x 到 m 维随机变量 $y = (y_1, y_2, \dots, y_m)^T$ 的线性变换:

$$y_i = \alpha_i^T x = \alpha_{1i} x_1 + \alpha_{2i} x_2 + \dots + \alpha_{mi} x_m$$

其中 $\alpha_i^T = (\alpha_{1i}, \alpha_{2i}, \dots, \alpha_{mi})$ 。

经过线性变换后的随机变量 y_i 的均值、方差和协方差统计量表示为:

$$E(y_i) = \alpha_i^T \mu, \quad i = 1, 2, \dots, m$$

$$\text{var}(y_i) = \alpha_i^T \Sigma \alpha_i, \quad i = 1, 2, \dots, m$$

$$\text{cov}(y_i, y_j) = \alpha_i^T \Sigma \alpha_j, \quad i, j = 1, 2, \dots, m$$

当随机变量 x 到随机变量 y 的线性变换满足如下条件时,变换后的 y_1, y_2, \dots, y_m 分别为随机变量 x 的第一主成分、第二主成分, ... 第 m 主成分。

(1) 线性变换的系数向量 α_i^T 为单位向量, 有 $\alpha_i^T \alpha_i = 1, i = 1, 2, \dots, m$ 。

(2) 线性变换后的变量 y_i 与 y_j 线性无关, 即 $\text{cov}(y_i, y_j) = 0 (i \neq j)$ 。

(3) 变量 y_1 是随机变量 x 所有线性变换中方差最大的, y_2 是 y_1 无关的所有线性变换中方差最大的。方差大 \rightarrow 坐标轴上打得散

上述条件给出了求解主成分的基本方法。根据优化目标和约束条件,我们可以用拉格朗日乘子法来求解主成分。下面以第一主成分为例求解推导:

$$\begin{aligned} \max \quad & \alpha_1^T \Sigma \alpha_1 \\ \text{s.t.} \quad & \alpha_1^T \alpha_1 = 1 \end{aligned}$$

定义的拉格朗日函数如下:

$$\mathcal{L} = \alpha_1^T \Sigma \alpha_1 - \lambda (\alpha_1^T \alpha_1 - 1)$$

对 α_1 求导并令其为0,有:

$$\frac{\partial L}{\partial \alpha_1} = \Sigma \alpha_1 - \lambda \alpha_1 = 0$$

λ 为 Σ 的特征值, α_1 为对应的单位特征向量。假设 α_1 是 Σ 最大特征值 λ_1 对应的单位特征向量,那么 α_1 和 λ_1 均为上述优化问题的最优解。


$$\text{var}(\alpha_1^T X) = \alpha_1^T \Sigma \alpha_1 = \lambda_1$$

同样的方法来求解第 k 主成分,第 k 主成分的方差的第 k 个特征值为:

$$\text{var}(\alpha_k^T X) = \alpha_k^T \Sigma \alpha_k = \lambda_k, k=1,2,\dots,m$$

最后梳理一下PCA的计算过程:

- (1) 对 m 行 n 列的数据 X 按照均值为0,方差为1进行标准化处理。
- (2) 计算标准化后的 X 的协方差矩阵 $C = \frac{1}{m} X X^T$ 。
- (3) 计算协方差矩阵 C 的特征值和对应的特征向量。
- (4) 将特征向量按照对应特征值大小排列成矩阵,取前 k 行构成矩阵 P 。
- (5) 计算 $Y = PX$ 即可得到经过PCA降维后的 k 维数据。



PCA可以解决维度灾难问题,是对原始特征空间的重构。